

杨行

(+86) 131-6207-0162 | 2679frank@gmail.com

个人总结

- 拥有 8 年异构平台 (CPU/GPU/DSP/NPU) 算子加速库开发经验, 专注 BLAS, DNN 等核心加速库的开发。
- 具有三年团队管理经验, 成功带领团队完成交付, 得到客户认可, 也曾跨团队领导项目开发。
- 拥有超强的学习能力, 追求卓越, 喜欢钻研技术, 乐于分享。

技术能力

- 技术方向: 加速库开发、算子优化、深度学习模型部署优化 (LLM, CNN), 熟悉 pytorch。
- 编程语言: C++/C、Python、CUDA、Make、CMake。
- 开发工具: AI 辅助编程、Verdi/SimVision、Git、JIRA、Jenkins。

工作经历

阿里达摩院 | 软件工程师 / 算子加速库 2024.12 至今

- 负责 gemm 类算子开发, 软硬件协同分析。

壁仞科技 | 软件工程师 / Team Leader / 算子加速库 2021.01 - 2024.11

- 从零开始开发 AI 领域的加速库 (DNN、BLAS), 在多种大模型场景下优化性能, 达到 A100 同等水平。
- 设计并实现了高效的算子注册框架和日志系统, 以及 kernel selection 算法。

海康威视 | 软件工程师 / AI 加速库 2017.07 — 2020.12

- 负责异构平台高性能卷积神经网络 (CNN) 库的开发, 优化芯片性能, 提升算法落地效率。
- 从业务需求到解决方案的端到端项目负责, 构建高效的应用方案, 实现智能算法的实际应用。

项目经历

CUTLASS 移植 | 掌握 CUTLASS 编程范式 2025.07 - 至今

- 预研分析 CUTLASS 框架, cute layout 算术, 并支持新的芯片架构, 初步实现泛化的 gemm 算子。

BLAS 产品化 | 性能对标 A100 / 专利 3 项 2023.06 - 2024.11

- 从无到有搭建框架, 测试, 算子开发, 算子选择, benchmark, CICD, 文档
- 泛化支持 LLM (qwen, llama2, gpt) 系列模型, 在第一代多款芯片上性能打平 A100
- 使能了多种优化策略, 包括 warp-specialized 编程范式, fused bias, fused grad 累加, BF16 累加等。

GEMM 极致优化实现 | 芯片利用率打满 / 专利 2 项 2021.09 - 2021.10, 2025.06 - 2025.08

- 在特定 shape 下, 通过手写汇编和 Verdi 波形分析, 实现了基于 vcore 和 tcore 平台的 GEMM 算法性能最优化。

DNN 框架开发 | 支撑 DNN 全栈验证 / 软著 1 项 2022.03 - 2023.06

- 参考 pytorch 开发深度学习框架及精度验证, 并设计基于 YAML 的算子表达方式, 实现了自动化精度验证和性能对标。

教育经历

台湾大学 | 电信研究所 | 学术型硕士研究生 2014.09 — 2017.01

- WIFI 802.11ax 协议设计, 分别在 IEEE access 期刊, 及通信领域顶会 globalcom 上发表两篇论文。

重庆大学 | 通信学院 | 工学学士 2010.09 — 2014.06

- 专业前 5%, 优秀毕业生, 获奖学金多次

其他信息

- 兴趣爱好: 铁三爱好者, 持续学习新技术, 积极参与技术社区分享。
- AI 领域专利 5 项, 软著 1 项, 通信领域专利一个, 论文 2 篇。

[1] Yang, Hang, D.-J. Deng, and K.-C. Chen, "On energy saving in ieee 802.11 ax," *IEEE Access*, vol. 6, pp. 47546–47556, 2018.

[2] Yang, Hang, D.-J. Deng, and K.-C. Chen, "Performance analysis of ieee 802.11 ax ul ofdma-based random access mechanism," in *GLOBECOM 2017-2017 IEEE Global Communications Conference*, IEEE, 2017, pp. 1–6.